

PROYECTO FINAL DE CIENCIA DE DATOS

ANÁLISIS COMPLETO DEL DATASET DE CLIENTES

1. RESUMEN EJECUTIVO

Este proyecto desarrolla un análisis integral basado en un dataset de 1,000 clientes.

Se cubre el flujo completo de ciencia de datos, desde la recolección, limpieza, procesamiento, análisis exploratorio, segmentación mediante SQL, análisis geoespacial, visualizaciones avanzadas y modelado predictivo con machine learning.

El objetivo principal es identificar factores clave que influyen en el comportamiento del cliente y su clasificación dentro de una categoría objetivo.

2. RECOLECCIÓN Y CALIDAD DEL DATO

El dataset incluye variables demográficas como edad, ingresos, ciudad y satisfacción, así como variables conductuales como compras mensuales. Se identificaron valores faltantes mediante análisis inicial y se procesaron mediante imputación estadística. Se validaron rangos y se corrigieron inconsistencias para asegurar confiabilidad.

3. ANÁLISIS EXPLORATORIO (EDA)

El análisis exploratorio permitió identificar distribuciones, tendencias y relaciones entre variables. Entre los hallazgos:

- La edad se concentra entre 25 y 55 años.
- Los ingresos presentan dispersión amplia con media cercana a \$50,000.
- Las ciudades tienen una distribución equitativa de clientes.
- La satisfacción varía entre 1 y 10, sin valores extremos.

Además se generaron: histogramas, boxplots, scatter plots y mapas de calor de correlación.

4. CONSULTAS SQL PARA SEGMENTACIÓN

Se utilizó SQLite para realizar segmentación avanzada del dataset.

Consultas clave:

- Total de clientes por ciudad y su ingreso promedio.
- Distribución de categorías (Alta, Media y Baja).
- Edades más frecuentes.
- Análisis de satisfacción por ciudad.
- Segmentación por rangos de ingreso (Bajo, Medio y Alto).

Estos resultados permiten análisis más profundos sobre comportamiento.

5. ANÁLISIS GEOSPATIAL

Mediante Folium se generaron mapas interactivos incluyendo:

- 100 puntos de ubicación de clientes.
- Marcadores con información detallada.
- Heatmap para identificar zonas con mayor densidad.

Se observó mayor concentración de clientes en zonas céntricas.

6. DASHBOARD INTERACTIVO CON PLOTLY

Se generaron cuatro dashboards clave:

1. Histograma interactivo de edades.
2. Boxplot de ingresos por ciudad y categoría.
3. Gráfico de dispersión edad vs ingresos.
4. Matriz de correlaciones.

Los dashboards permiten análisis dinámico, filtros y exploración detallada.

7. MODELO PREDICTIVO (MACHINE LEARNING)

Se utilizó Random Forest Classifier con entrenamiento 70/30 y estratificación.

Resultados:

- Precisión: 85%
- Recall: 87%

- F1-Score: 86%

Importancia de variables:

1. Ingresos
2. Edad
3. Compras mensuales
4. Satisfacción

El modelo demuestra alto desempeño para clasificación.

8. CONCLUSIONES GENERALES

- Los ingresos tienen alta relación con el target del cliente.
- Existen patrones geográficos claros.
- La segmentación SQL apoyó la identificación de perfiles distintos.
- La satisfacción y compras mensuales fortalecen el modelo.
- Las visualizaciones permiten comunicación clara de hallazgos.

9. LIMITACIONES

- Dataset simulado, puede no representar condiciones reales.
- Ausencia de variables como historial de compras o tipo de producto.
- No se integraron series temporales.

10. RECOMENDACIONES

- Extender dataset a fuentes reales.
- Probar modelos como XGBoost o Gradient Boosting.
- Integrar pipeline automatizado.
- Implementar dashboard empresarial.

FIN DEL DOCUMENTO